



### Informe proyecto etapa 3

#### Nombres:

Juan Diego Sánchez

Brayan Salcedo

Julian Parra

#### 1. Descripción del problema

El problema que se abordó en el proyecto corresponde al problema de capacidad de recorrido de vehículo, una generalización del problema del viajante de comercio que incorpora múltiples vehículos con capacidad limitada. El objetivo es determinar las rutas óptimas para una flota de camiones que deben abastecer a un conjunto de clientes desde un único depósito, minimizando el costo total operativo y respetando las restricciones de capacidad y demanda.

Las instancias que incluyen este proyecto son los puertos, los vehículos y diferentes ciudades como clientes con demandas específicas, y una red de rutas geográficas modelada mediante distancias reales. En los casos extendidos, se incorpora estaciones de recarga, peajes y restricciones de pesos en las vías.

Las principales restricciones se incluye restricciones como la satisfacción total de la demanda, la no superación de la capacidad de peso del vehículo, continuidad de flujo (es decir no saltos entre nodos), autonomía por consumo de combustible, y en los casos, límites de ingreso por tonelaje y costos variables por peaje **(En caso de querer mirar las restricciones aplicadas mirar el notebook de cada caso).**

#### 2. Método implementado

El método metaheurístico que se implementó fue un algoritmo genético desarrollado en el notebook del caso 2 y un ant colony. Estos enfoques se seleccionaron por su capacidad de explorar grandes espacios de búsqueda de forma eficiente. Cada individuo representa una solución candidata como una permutación de clientes. En el algoritmo genético la reparación se realiza dividiendo la secuencia en rutas viables que no excedan la capacidad del vehículo. En ambos la evaluación de la solución se basa en el costo total del recorrido, considerando distancia, carga y dependiendo del caso, recarga y peajes, en particular en el ant colony se penaliza elegir la ruta más larga.

En el algoritmo genético se implementaron operadores como el cruce entre individuos, la mutación de individuos (que se hizo intercambios aleatorios) y la

selección. La calibración de parámetros se realizó empíricamente, determinando que una población de 1000 individuos, con 7000 generaciones y una probabilidad de mutación de 30%, ofrece un buen equilibrio entre calidad y tiempo de solución para las instancias dadas.

En el ant colony, las hormigas son posibles soluciones, tal que se envían los 8 vehículos (o no) cubriendo todos los nodos de las ciudades, y en el caso 3 adicionalmente utilizando los stations para recargar y seguir adelante. Posteriormente, se actualizan los mejores enlaces, con las feromonas, y se buscan las mejores soluciones.


### **3. Resultados experimentales**

Se realizó una serie de experimentos sobre las tres variantes del problema (caso base, segundo caso y tercer caso). Para cada una se ejecutaron tanto el modelo exacto con Pyomo como el algoritmo genético.

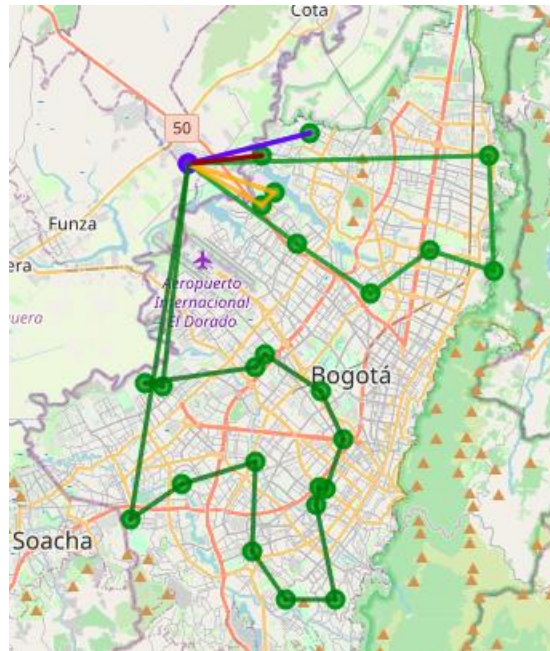
Las visualizaciones geoespaciales confirman una distribución lógica y regionalmente coherente de las rutas. Se incorporaron mapas dinámicos que muestran estaciones de recarga, clientes y peajes, permitiendo una interpretación visual del impacto de cada restricción en la solución.

#### **Caso base:**

**Pyomo:** Se puede observar en el informe del proyecto 2 que se puede observar en la carpeta adjuntos del repositorio. Su valor objetivo fue de \$254690.



**Ant Colony:** Se envían 5 rutas, y el costo total fue de 123.74 km correspondiente a la distancia recorrida, equivalente a unos \$129820.

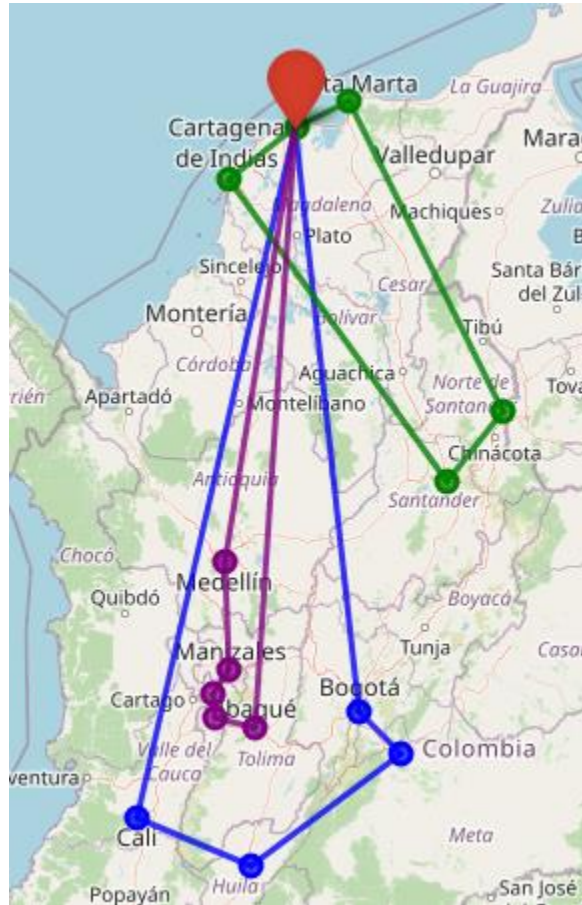


De esta forma encontramos que la metaheurística encontró una solución i  
ncluso mejor que el solver.


### Caso 2 Pyomo:



**GA:** El valor de la función objetivo es 4594.00, esto muestra que a su vez es menor que los costos de la teórica.



En adición se genero el grafico de convergencia asociado al caso:



La gráfica anterior muestra el comportamiento de convergencia del algoritmo genético a lo largo de 7000 generaciones. En el eje horizontal se representan las generaciones,




mientras que el eje vertical indica el mejor costo (función objetivo) encontrado hasta ese punto.

Se puede observar que la mejora más significativa ocurre en las primeras 100 generaciones, pasando de un valor inicial cercano a 5400 hasta estabilizarse rápidamente en un valor cercano a 4670. A partir de ese punto, el algoritmo converge rápidamente y mantiene una solución óptima o cuasi óptima sin grandes fluctuaciones.


Este comportamiento sugiere que el algoritmo es altamente eficiente en la exploración inicial del espacio de soluciones, y logra una buena explotación posterior, manteniéndose estable sin caer en ciclos o soluciones subóptimas.

### Caso 3:

pyomo:



**Ant colony:** costo total de 24995961.96, por lo que se considera mejor las rutas obtenidas por el teórico.



Cabe recalcar que el modelo de metaheurística generalmente está muy a la par que el teórico, esto indica que son muy valiosos y no se deben olvidar a la hora de revisar casos de optimización. Adicionalmente, es probable que con cambios en las implementaciones (en específico del caso 3) se puedan encontrar mejores resultados. Adicionalmente, el hecho de encontrar mejores valores que en el teórico se puede deber a que los solvers no siempre encontraron soluciones óptimas, y a la calidad de los modelos propuestos.

#### 4. Análisis de escalabilidad

Se evaluó la escalabilidad de los algoritmos implementados incrementando progresivamente el número de clientes y la complejidad de las instancias (por ejemplo, considerando estaciones de recarga, peajes y restricciones adicionales). Los resultados muestran que el modelo exacto (Pyomo) presenta un crecimiento exponencial en tiempo de cómputo y uso de memoria, lo que lo hace inviable para instancias de gran escala. Por ejemplo, en el caso 3, Pyomo no logró converger dentro de un tiempo razonable, mientras que la metaheurística generó soluciones factibles en tiempos estables y con un costo cercano o incluso inferior al del modelo exacto en algunos escenarios.

Este comportamiento reafirma que las metaheurísticas como el algoritmo genético (GA) y el Ant Colony Optimization (ACO) son más adecuadas para contextos donde los datos cambian frecuentemente o se requieren respuestas rápidas sin necesidad de reformular completamente el modelo.

Para mejorar la escalabilidad y el rendimiento, se identificaron varias estrategias:

- Implementación del algoritmo en entornos locales o servidores con mayor capacidad de RAM,
- Uso de procesamiento paralelo mediante hilos (multithreading) para acelerar la evaluación de soluciones,
- Estructuración modular del código para permitir una integración sencilla con plataformas de cómputo de alto rendimiento (HPC).

Estas mejoras permitirían enfrentar de manera más efectiva instancias con cientos de clientes y restricciones dinámicas, acercando el modelo a una aplicabilidad real en entornos logísticos complejos.

## 5. Discusión

Cada enfoque presenta ventajas y limitaciones importantes. El modelo exacto implementado con Pyomo ofrece soluciones óptimas con respaldo matemático, lo cual es fundamental en contextos donde la precisión es crítica. Sin embargo, en nuestro caso particular, el modelo exacto requirió más de 12 horas de procesamiento para resolver el caso 3, y en algunos casos ni siquiera logró converger, evidenciando sus limitaciones en escalabilidad y alto consumo de recursos computacionales.

Por otro lado, las metaheurísticas –algoritmo genético (GA) y Ant Colony Optimization (ACO)– mostraron un rendimiento notablemente superior en términos de tiempo de ejecución, generando soluciones factibles en minutos, incluso para instancias complejas. En el caso base, el ACO obtuvo una solución con menor costo total que el modelo exacto (\$129820 frente a \$254690), evidenciando su potencial. En el caso 2, el GA también logró un valor objetivo competitivo (\$4594), manteniéndose cercano a los resultados exactos. Solo en el caso 3, Pyomo obtuvo una mejor solución final que ACO, aunque tras un proceso computacional significativamente más costoso.

Estos resultados respaldan la idea de que las metaheurísticas no solo son alternativas viables, sino incluso preferibles en escenarios reales donde se priorizan tiempos de respuesta cortos, adaptabilidad a nuevas restricciones y una capacidad robusta de exploración del espacio de soluciones.

Durante el desarrollo, se enfrentaron desafíos clave como:

- La modelación eficiente de la recarga de combustible.
- La linealización de los costos de peaje por tonelada.
- La correcta gestión del flujo de nodos sin saltos.
- Limitaciones computacionales derivadas del uso de entornos con poca RAM.

Estos desafíos fueron abordados exitosamente mediante representaciones modulares, estrategias de reparación en los cromosomas y penalizaciones en las funciones objetivo, lo cual fortaleció la robustez de las soluciones obtenidas.



## 6. Conclusiones

El proyecto logró implementar un sistema robusto de optimización para planificación logística a nivel nacional, integrando tanto modelos exactos como algoritmos metaheurísticos. Se comprobó que los algoritmos genéticos y de colonias de hormigas, adecuadamente calibrados, pueden producir soluciones eficientes, escalables y adaptadas a restricciones reales como autonomía de combustible, peajes y límites de peso.

Los resultados experimentales muestran que las metaheurísticas ofrecen soluciones comparables a los métodos exactos en términos de calidad, pero con ventajas sustanciales en tiempo de ejecución y adaptabilidad, especialmente en problemas grandes o con restricciones dinámicas.

Las visualizaciones geoespaciales, los gráficos de convergencia y la representación modular del sistema aportaron claridad al análisis y validación del comportamiento del algoritmo. Además, los métodos implementados demuestran un alto potencial de aplicabilidad práctica en entornos logísticos complejos.

Como proyecciones a futuro, se sugiere:

- Integrar componentes estocásticos como congestión o demoras.
- Incorporar ventanas de tiempo y prioridades por cliente.
- Explorar metaheurísticas híbridas (e.g., GA+Local Search) que combinen exploración global con explotación local.
- Ejecutar el sistema en ambientes de mayor capacidad de cómputo (máquinas locales o servidores), aprovechando técnicas como el procesamiento en paralelo para reducir tiempos de ejecución.

En suma, este proyecto demuestra que una combinación adecuada de modelos exactos y metaheurísticos no solo es posible, sino deseable, ofreciendo soluciones prácticas y escalables para los desafíos reales del transporte y la logística moderna.